Lemorzsolódás előrejelzése adatbányászati módszerekkel

A Zenara streaming szolgáltató vezetősége kiértékelte az előfizetői adatok elemzésének eddigi eredményeit. A 2023 előtti időszakban jellemzően az online felületen kezelt (azaz nem call centerrel is rendelkező ügyfélkapcsolati ügynökség által kiszolgált) szerződések felmondásával volt a gond. Ugyanakkor a 2024 februárja során a panaszirodáktól érkező nyugtalanító visszajelzések hátterében nem ez állt. A megnövekedett, jellemzően az 1 éven túli törlésráta az új, 2023 január 1-je óta értékesített előfizetői csomagok (termékek) esetében az elsődlegesen okos TV-ről használt előfizetésekre volt jellemző. Ezen felmondások többsége pedig a New York államban élőügyfelekre koncentrálódott. Arra utaló eredmények is születtek, hogy számos esetben csak az ajándékért kötik meg a szerződést az ügyfelek, majd díjhátralékkal megszűnik az előfizetésük.

Az eddigi elemzések ugyanakkor nem tárták fel a pontos okokat, a lemorzsolódást előidéző tényezőket és a közöttük fennálló összefüggéseket. A Zenara vezetősége éppen ezért úgy határozott, hogy további, mélyebb elemzések elvégzését rendeli el. Az elemzést pedig New York államban élő ügyfelek adatait rendszerező adatbázis alapján kívánja meghatározni.

Az adatbázis (ZenaraChurn.xlsx) a következő ügyfelekre vonatkozó adatokat tartalmazza:

1. SubscriptionID
2. HH Income
3. Home Ownership
4. Ethnicity
5. dummy for Children
6. Year Of Residence
7. Age range
8. Language
9. Address
10. State
11. City
12. County
13. Zip Code
14. monthly fee
15. Device
16. Nielsen Prizm
17. Reward program (hányszor vett részt az adott előfizető jutalomprogramban)
18. Source Channel
19. Subscriber

4. feladat

Alkalmazzák a Gini index képletét és a *Golf_adatok_Gini.xlsx* táblázatban:

- számolják ki az Outlook 6 és 4 értékhez tartozó értékeket
- döntsék el az Outlook mely értéke alapján történjen az első vágás (E31 cella)
- végül válasszák ki melyik következő változó alapján történjen a tovább-bontás (34. sor) és töltsék ki a kapcsolódó táblázatot

Készítsenek döntési fa modellt a Gini index alkalmazásával!

4.1. feladat

A modellek elkészítése előtt:

- vizsgálják meg az adathalmazt (*Read Excel* operátor futtatása)
- készítsenek halmozott oszlopdiagramot a körzetek (county) és lemorzsolódási státusz (Subscriber) kapcsolatának vizsgálatára (Read Excel operátor futtatása után, az operátor az outputjában)
- készítsenek hisztogramot a *Reward program* változóra a *Subscriber* változó szerint színezve (Read Excel operátor futtatása után, az operátor outputjában)

4.2. feladat

Készítsen modellt, amely alapján meghatározza a lemorzsolódó ügyfelek jellemzőit. Ehhez több különböző statisztikai módszert is próbáljon ki. Az elemzések keretében mutasson be döntési fa (Gini, Gain ratio) és naiv Bayes logikára épülő modellt is. **Az adatok első 70%-a legyen a tréning, a maradék 30% a teszt adatbázis.**

A modelleket az alábbiak figyelembevételével készítse el:

- az adatok beolvasása után használják a ***„Multiply"*** operátort, amely lehetővé teszi, hogy a beolvasott adathalmazt többször is fel lehessen használni (és így több modellt is fel tudnak építeni)
- a ***„Split Data"*** operátor segítségével osszák fel az adathalmazt minden modellépítés során tanító és teszt adathalmazra
- döntési fa modell esetén először alkalmazzák a Gini index módszert, majd készítsenek új fát a Gain ratio módszerrel is, az alábbi paraméterek alkalmazásával:
    - Maximal depth: 10
    - Apply pruning: confidence: 0.25
    - Apply prepruning: minimal gain: 0.1 (a többinél paraméternél az alapbeállítás maradhat)
- Naiv Bayes modell is alkalmazzák, illetve futtassák.
- A modellek kiértékelésére alkalmas eszközöket is építsék be a modellekbe a megfelelő ***„Performance"*** operator alkalmazásával.

Az elkészült modellek teljes pontosságát (accuracy) illetve a lemorzsolódók előrejelzésének (P_{no}) pontosságát tekintve melyik teljesít a legjobban?

Segédlet

- *Pruning:* „A döntési fák metszése (pruning) során a felépített fát kicsit egyszerűsítjük, egyes csomópontokat eltávolítunk. Feltételezzük, hogy a felépítés során a ***fa túltanult***, azaz megtanult olyan esetiségeket is, amelyek csak az aktuális tanítóhalmazra jellemzőek, nem általánosan érvényes szabályszerűségek." (Bodon – Buza, 2014, 149. old.) A gyakorlatban ez azt jelenti, hogy ha egy fának egy ágát egy levéllé összevonjuk, és az eredményváltozó osztályozásával kapcsolatos döntés már legalább a paraméterben megadott biztonságú (esetünkben 25%), akkor azt az ágat a fán levéllé "változtatja" a program.
- *Prepruning*: Korai kilépési feltételek megfogalmazását jelenti. Ha a fa építésénél még nem értük el a maximális mélységet, de az ebben a pontban megadott feltételek közül valamelyik sérül (pl. a vágás során az information gain nem éri el legalább a 10%-ot = minimal gain: 0.1), akkor a fa ezen ágán levelet képzünk, és nem vágunk tovább.