Lemorzsolódás előrejelzése adatbányászati módszerekkel

A Zenara streaming szolgáltató vezetősége kiértékelte az előfizetői adatok elemzésének eddigi eredményeit. A 2023 előtti időszakban jellemzően az online felületen kezelt (azaz nem call centerrel is rendelkező ügyfélkapcsolati ügynökség által kiszolgált) szerződések felmondásával volt a gond. Ugyanakkor a 2024 februárja során a panaszirodáktól érkező nyugtalanító visszajelzések hátterében nem ez állt. A megnövekedett, jellemzően az 1 éven túli törlésráta az új, 2023 január 1-je óta értékesített előfizetői csomagok (termékek) esetében az elsődlegesen okos TV-ről használt előfizetésekre volt jellemző. Ezen felmondások többsége pedig a New York államban élőügyfelekre koncentrálódott. Arra utaló eredmények is születtek, hogy számos esetben csak az ajándékért kötik meg a szerződést az ügyfelek, majd díjhátralékkal megszűnik az előfizetésük.

Az eddigi elemzések ugyanakkor nem tárták fel a pontos okokat, a lemorzsolódást előidéző tényezőket és a közöttük fennálló összefüggéseket. A Zenara vezetősége éppen ezért úgy határozott, hogy további, mélyebb elemzések elvégzését rendeli el. Az elemzést pedig New York államban élő ügyfelek adatait rendszerező adatbázis alapján kívánja meghatározni.

Az adatbázis (ZenaraChurn.xlsx) a következő ügyfelekre vonatkozó adatokat tartalmazza:

1. SubscriptionID
2. HH Income
3. Home Ownership
4. Ethnicity
5. dummy for Children
6. Year Of Residence
7. Age range
8. Language
9. Address
10. State
11. City
12. County
13. Zip Code
14. monthly fee
15. Device
16. Nielsen Prizm
17. Reward program (hányszor vett részt az adott előfizető jutalomprogramban)
18. Source Channel
19. Subscriber

4. feladat

Alkalmazzák a Gini index képletét és a *Golf_adatok_Gini.xlsx* táblázatban:

- számolják ki az Outlook 6 és 4 értékhez tartozó értékeket
- döntsék el az Outlook mely értéke alapján történjen az első vágás (E31 cella)
- végül válasszák ki melyik következő változó alapján történjen a tovább-bontás (34. sor) és töltsék ki a kapcsolódó táblázatot

4.1. Feladat

A modellek elkészítése előtt:

- vizsgálják meg az adathalmazt (*Read Excel* operátor futtatása)
- készítsenek halmozott oszlopdiagramot a körzetek (county) és lemorzsolódási státusz (Subscriber) kapcsolatának vizsgálatára (Read Excel operátor futtatása után, az operátor az outputjában)
- készítsenek hisztogramot a *Reward program* változóra a *Subscriber* változó szerint színezve (Read Excel operátor futtatása után, az operátor outputjában)

Készítsenek döntési fa modellt a Gini index alkalmazásával!